密级状态：绝密(　　)　　秘密(　　)　　内部(　　)　　公开(√)

# Rockchip Trouble shooting RKNN-Toolkit CN

（技术部，图形显示平台中心）

| | | |
|---|---|---|
| 文件状态：<br>[　] 正在修改<br>[√] 正式发布 | 当前版本： | 1.1 |
| | 作　　者： | HPC |
| | 完成日期： | 2019-08-22 |
| | 审　　核： | 卓鸿添 |
| | 完成日期： | 2019-08-22 |

福州瑞芯微电子股份有限公司

Fuzhou　Rockchips　Semiconductor　Co . , Ltd

# 更新记录

| 版本 | 修改人 | 修改日期 | 修改说明 | 核定人 |
|---|---|---|---|---|
| 0.9 | HPC | 2019-04-01 | 初稿 | 卓鸿添 |
| 1.0 | HPC | 2019-07-18 | 增加一些常见问题 | 卓鸿添 |
| 1.1 | HPC | 2019-08-22 | 增加深度神经网络模型设计建议 | 卓鸿添 |
| | | | | |
| | | | | |

目录

# 1. RKNN Toolkit 用法相关问题

## 1.1. rknn.config 函数，为什么 channel_mean_value 有 4 个值？如果是 rgb 图像，还是 4 个值吗？

rknn.config 里面的 channel-mean-value: 用来设置预处理的命令行参数。包括四个值(M0 M1 M2 S0),前三个值为均值参数,后面一个值为 Scale 参数。对于输入数据是三通的(Cin0, Cin1, Cin2)数据来讲,经过预处理后,输出的数据为(Cout0,Cout1, Cout2),计算过程如下:

Cout0 = (Cin0 - M0)/S0

Cout1 = (Cin1 - M1)/S0

Cout2 = (Cin2 - M2)/S0

例如,如果需要将输入数据归一化到[-1, 1]之间,则可以设置这个参数为(128 128 128 128);

如果需要将输入数据归一化到[0, 1]之间,则可以设置这个参数为 (0 0 0 255)。

## 1.2. 当输入图像是单通道灰度图片时， rknn.config 接口如何设定

请参考 1.1 的回答，当输入图像是单通道时，只用到”Cout0 = (Cin0 - M0)/S0”，因此你可以设置为(M0, 0, 0, S0)，M1、M2 的值不会被用到。

## 1.3. rknn.config 函数，怎么设定 scale 参数，即把输入的 range 压缩到一定的范围。e.g. from (0-255) to (0-1)

参考 1.1 的回答。

## 1.4. 当输入的 channel 大于 3 时，rknn.config 接口如何设定

比如输入维度为 1x25x25x96（NHWC 格式）时，channel_mean_value 及 reorder_channel 均不要设置。这种情况下默认所有通道的 mean 为 0，scale 为 1。

## 1.5. rknn.Inference()接口调用多次后出错或者卡住

如果出错信息类似：

```
Traceback (most recent call last):
  File "rknn_pic_to_emb.py", line 63, in <module>
  File "rknn_pic_to_emb.py", line 42, in get_embedding
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/site-packages/rknn/
api/rknn.py", line 234, in inference
  File "rknn/api/redirect_stdout.py", line 76, in rknn.api.redirect_stdout.redir
ect_stdouter.redirect_stdout.func_wrapper
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/contextlib.py", lin
e 81, in __enter__
  File "rknn/api/redirect_stdout.py", line 48, in stdout_redirector
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
622, in TemporaryFile
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
262, in _mkstemp_inner
OSError: [Errno 24] Too many open files: '/tmp/tmp5yw4m_22'
Traceback (most recent call last):
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/weakref.py", line 6
24, in _exitfunc
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/weakref.py", line 5
48, in __call__
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
799, in _cleanup
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/shutil.py", line 48
2, in rmtree
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/shutil.py", line 48
0, in rmtree
OSError: [Errno 24] Too many open files: '/tmp/tmp_d63w4jh'
```

请将 RKNN Toolkit 升级到 0.9.9 及以后。

## 1.6. rknn.inference()推理速度慢的问题

这个问题有两方面的现象：

1) 进行前向推理测试速度慢，经测试 mobilenet-ssd 有的图片耗时在 0.5 秒以上

2) 模型 rknn.inference 的时间和 rknn.eval_perf()时间相差较大，比如

| | | | | |
|---|---|---|---|---|
| 理论计算时间(单图) | 1.79ms | 8.23ms | 7.485ms | 30.55ms |
| 实际计算时间(单图) | 21.37ms | 39.82ms | 33.12ms | 76.13ms |

实测帧率慢的问题，有两方面的原因：

1. 使用 pc + adb 的方式传图片比较慢，这种对高帧率的网络影响很大比如理论 1.79ms 的网络。

2. RKNN Toolkit 0.9.8 及以前的版本的实现有 BUG，这个问题在 0.9.9 中已经解决。

对于更真实的实测帧率，可以直接在板子上使用 c/c++ api 进行测试。

## 1.7. RKNN Toolkit 0.9.9 版本第一次 inference 很慢

RKNN Toolkit 0.9.9 版本将加载模型推迟到第一次 inference 时，因此第一次 inference 比较慢，这个问题将在下个版本中解决。

## 1.8. 在开发板上用 RKNN Toolkit 转换模型时开启 pre_compile=true 出错

Arm64 版本的 RKNN Toolkit 暂时还不支持 pre_compile，如果需要打开 pre_compile，建议在开发机上用 x86 版本 RKNN Toolkit 进行转换。

## 1.9. YOLO 前向测试返回的 outputs 为[array1，array2]，长度分别为[10140，40560]，返回值含义是什么

rknn.inference 返回的 outputs 是一个 numpy ndarray 的列表，每个模型输出数据大小个数都不一样，用户需要自行查找模型的对应输出和解析规则。

## 1.10. RKNN Toolkit 支持的量化方式

RKNN 支持两种量化机制：

- **Quantization-aware training**

  可以参考 Tensorflow quantization-aware training (https://github.com/tensorflow/tensorflow/tree/master/tensorflow/contrib/quantize)，这种方法要求用户有一定的 fine tune 重训练的基础。使用 RKNN Toolkit 导入量化后的模型时使用 rknn.build(do_quantization=False)，这时 RKNN Toolkit 将使用模型自身的量化参数，因此在量化精度上不会有损失。

- **Post training quantization**

  使用这种方式时，用户导入已训练好的 float point 模型，RKNN Toolkit 根据用户提供的 dataset 进行量化。Dataset 应尽量覆盖模型可能的输入类型。官方提供的 example 为了简单一般只放一张图片，建议多放一些。

  目前 RKNN Toolkit 支持 3 种量化方式：

✓ asymmetric_quantized-u8（default）

这是 tensorflow 支持的量化方式，也是 google 推荐的。根据”Quantizing deep convolutional networks for efficient inference: A whitepaper”论文的描述，对于大部分网络，这种量化方式对精度的损失最小。

其计算公式如下：

$$quant = round\left(\frac{float\_num}{scale}\right) + zero\_point$$
$$quant = cast\_to\_bw$$

其中 quant 代表量化后的数， float_num 代表 float， scale 是一个 float32 类型， zero-points 是一个 int32 类型，代表实数为 0 时对应的量化值， 最后把 quant 饱和到【range_min, range_max】

$$range\_max = 255$$
$$range\_min = 0$$

因为当前只支持 u8

对应的反量化

$$float\_num = scale(quant - zero\_point)$$

✓ dynamic_fixed_point-8

对于有些模型而言，dynamic_fixed_point-8 量化的精度比 asymmetric_quantized-u8 高。

其公式如下

$$quant = round(float\_num * 2^{fl})$$
$$quant = cast\_to\_bw$$

其中 quant 代表量化后的数， float_num 代表 float， fl 是左移的 bits， 最后把 quant 饱和到【range_min, range_max】

$$range\_max = 2^{bw-1} - 1$$
$$range\_min = -(2^{bw-1} - 1)$$

若 bw=8，则范围在[-127, 127]

✓ dynamic_fixed_point-16

dynamic_fixed_point-16 的量化公式与 dynamic_fixed_point-8 一样，只不过 bw=16。对于 rk3399pro/rk1808 而言，NPU 里面都带有 300Gops int16 的计算单元，对于某些量化到 8 位精度损失较大的网络，可以考虑使用此量化方式。

## 1.11. 转换模型时如果 do_quantization 为 False，是否也会进行量化，量化精度是什么？（因为转换后模型体积小了接近一半）

分两种情况，当导入的模型是量化的模型时，do_quantization=False 会使用该模型里面的量化参数，具体请参考 1.9 的回答。当导入的模型是非量化模型时，do_quantization=False 不会做量化的操作，但是会把权重从 float32 转成 float16，这块不会有精度损失。

## 1.12. 构建 RKNN 模型（调用 build 接口）时，设置 do_quantization=False 能构建成功，但是设成 True，构建失败

错误信息如下：

```
T Caused by op 'fifo_queue_DequeueMany', defined at:
T   File "test.py", line 52, in <module>
T     ret = rknn.build(do_quantization=True, dataset='./dataset.txt')
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/api/rknn.py", line 162, in build
T     ret = self.rknn_base.build(do_quantization=do_quantization, dataset=dataset, pack_vdata=pre_compile)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/base/rknnlib/app/tensorzone/tensorprovider.py", line 154, in get_output
T     return self.queue_task.queue.dequeue_many(batch_size)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/ops/data_flow_ops.py", line 478, in dequeue_many
T     self._queue_ref, n=n, component_types=self._dtypes, name=name)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/ops/gen_data_flow_ops.py", line 3487, in queue_dequeue_many_v2
T     component_types=component_types, timeout_ms=timeout_ms, name=name)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/op_def_library.py", line 787, in _apply_op_helper
T     op_def=op_def)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/util/deprecation.py", line 488, in new_func
T     return func(*args, **kwargs)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/ops.py", line 3274, in create_op
T     op_def=op_def)
T   File "/home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/ops.py", line 1770, in __init__
T     self._traceback = tf_stack.extract_stack()
T OutOfRangeError (see above for traceback): FIFOQueue '_0_fifo_queue' is closed and has insufficient elements (requested 1, current size 0)
T         [[node fifo_queue_DequeueMany (defined at /home/ljqi/work/rock3399pro/RKNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/base/rknnlib/app/tensorzone/tensorprovider.py:154)  = QueueDequeueManyV2[_class=["loc:@input_116/cond/Switch_2"], component_types=[DT_FLOAT, DT_INT32], timeout_ms=-1, _device="/job:localhost/replica:0/task:0/device:CPU:0"](fifo_queue, fifo_queue_DequeueMany/n)]]
Build onnx failed!
```

这是由于 dataset.txt 里没有数据，或者数据是我们不支持的格式，建议用 jpg 或 npy。

## 1.13. 安装 RKNN-Toolkit 时出现”undefined symbol: PyFPE_jbuf”错误

出现这个错误的原因是 Python 环境不干净，比如在两个不同的路径里都安装了 numpy。可以重新创建一个干净的 Python 环境后再试。

## 1.14. 在 Toybrick 上安装 RKNN-Toolkit 出现“Permission Denied”错误。

原因是没有 root 权限，安装的时候需要加上’--user’选项。

## 1.15. RKNN 是否多输入的模型转换？

目前不支持多输入模型转换，该功能正在评估中。

## 1.16. RKNN 量化过程中的 dataset 起什么作用？为什么量化需要和 dataset 关联？

RKNN 量化过程中，需要找到合适的量化参数，比如 scale 或者 zero point，这些量化参数的选择需要根据实际的输入做 inference 来确定。

## 1.17. rknn.inference()是否支持同时输入多张图片？或者说支持 batch 输入。

目前不支持同时输入多张图片。

## 1.18. 什么时候能支持 pytorch 和 mxnet 模型直接转成 rknn？

Pytorch 直接转换成 rknn 的功能正在开发中，mxnet 暂时没有计划。

## 1.19. RKNN-Toolkit-V0.9.9 版本生成的 pre-compile 模型在 0.9.6 版本驱动上无法运行？

RKNN-Toolkit-V1.0.0 版本生成的预编译模型不能在 NPU 驱动版本小于 0.9.6 的设备上运行；旧版本 RKNN-Toolkit（V0.9.9 及之前的版本）生成的预编译模型不能在安装了新版本 NPU 驱动的设备上运行。驱动版本号可以通过 get_sdk_version 接口查询。

## 1.20. 加载模型时，numpy 模块报错：Object arrays cannot be loaded when allow pickle=False.

错误信息如下：

```
E Catch exception when building RKNN model!
T Traceback (most recent call last):
T   File "rknn/api/rknn_base.py", line 459, in rknn.api.rknn_base.RKNNBase.build
T   File "rknn/api/rknn_base.py", line 952, in rknn.api.rknn_base.RKNNBase._quantize
T   File "rknn/base/RKNNlib/app/tensorzone/workspace.py", line 231, in rknn.base.RKNNlib.app.tensorzone.workspace.Workspace.load_data
T   File "rknn/base/RKNNlib/app/tensorzone/graph.py", line 32, in rknn.base.RKNNlib.app.tensorzone.graph.Graph.load_data
T   File "rknn/base/RKNNlib/RKNNnet.py", line 379, in rknn.base.RKNNlib.RKNNnet.RKNNNet.load_data
T   File "rknn/base/RKNNlib/RKNNnet.py", line 391, in rknn.base.RKNNlib.RKNNnet.RKNNNet._load_old_data
T   File "rknn/base/RKNNlib/RKNNnet.py", line 392, in rknn.base.RKNNlib.RKNNnet.RKNNNet._load_old_data
T   File "/home/raul/work/python-env/rknn-package-tvenv/lib/python3.5/site-packages/numpy/lib/npyio.py", line 447, in load
T     pickle_kwargs=pickle_kwargs)
T   File "/home/raul/work/python-env/rknn-package-tvenv/lib/python3.5/site-packages/numpy/lib/format.py", line 692, in read_array
T     raise ValueError("Object arrays cannot be loaded when "
T ValueError: Object arrays cannot be loaded when allow_pickle=False
```

这个错误是由于 numpy 升级到 1.16.3 以后，加载 numpy 文件时的参数 allow_pickle 默认值发生变化导致的（从 Ture 改成了 False）。解决方法有两种：一是将 numpy 版本降到 1.16.2 或更低的版本；二是将 RKNN-Toolkit 更新到 1.0.0 或更新的版本。

## 1.21. 联机调试时，rknn_init 失败，出现 RKNN_ERR_MODEL_INVALID 的错误

错误信息如下：

```
E RKNNAPI: rknn_init,    msg_load_ack fail, ack = 1, expect 0!
E Catch exception when init runtime!
T Traceback (most recent call last):
T     File "rknn/api/rknn_base.py", line 646, in rknn.api.rknn_base.RKNNBase.init_runtime
T     File "rknn/api/rknn_runtime.py", line 378, in
rknn.api.rknn_runtime.RKNNRuntime.build_graph
```

```
T Exception: RKNN init failed. error code: RKNN_ERR_MODEL_INVALID
```

出现该错误一般有两种情况：

1）在生成 rknn 模型时，使用了 pre_compile=True 的选项，而不同版本的 RKNN Toolkit 和驱动是有对应关系的，建议将 RKNN Toolkit 和板子的固件都升级到最新的版本。

2）在生成 rknn 模型时，没有使用 pre_compile=True 的选项，这时一般是系统固件太老了，建议将板子的固件升级到最新的版本。

## 1.22. 联机调试时，rknn_init 失败，出现 RKNN_ERR_DEVICE_UNAVAILABLE 的错误

错误信息如下：

```
E RKNNAPI: rknn_init, driver open fail! ret = -9!
E Catch exception when init runtime!
T Traceback (most recent call last):
T File "rknn/api/rknn_base.py", line 617, in rknn.api.rknn_base.RKNNBase.init_runtime
T File "rknn/api/rknn_runtime.py", line 378, in rknn.api.rknn_runtime.RKNNRuntime.build_graph
T Exception: RKNN init failed. error code: RKNN_ERR_DEVICE_UNAVAILABLE
```

这个问题的原因比较复杂，请按以下方式排查：

1） 确保 RKNN Toolkit 及板子的系统固件都已经升级到最新版本。

2） 确保 adb devices 能看到设备，并且 init_runtime()的 target 和 device_id 设置正确

3） 如果使用 RKNN Toolkit 1.1.0 及以上版本，请确保 rknn.list_devices()能看到设备，并且 init_runtime()的 target 和 device_id 设置正确

4） 如果使用的是计算棒或者 RK1808 EVB 版的 NTB 模式，请确保已经调用 update_rk1808_usb_rule.sh （在 RKNN Toolkit 发布包中）来获得 USB 设备的读写权限。（可以先使用 sudo 运行该 python 脚本看是否还出现问题）

5） 如果是直接在 RK3399/RK3399Pro 上运行 AARCH64 版本的 RKNN Toolkit，请确保系统固件都已经升级到最新版本。

## 1.23. 调用 rknn.build()时如果设置 pre_compile=True 报错，不设置可以转换成功。

错误信息如下：

```
E Catch exception when building RKNN model!
```

```
T Traceback (most recent call last):
T   File "rknn/api/rknn_base.py", line 515, in rknn.api.rknn_base.RKNNBase.build
T   File "rknn/api/rknn_base.py", line 439, in rknn.api.rknn_base.RKNNBase._build
T   File "rknn/base/ovxconfiggenerator.py", line 187, in
rknn.base.ovxconfiggenerator.generate_vx_config_from_files
T   File "rknn/base/RKNNlib/app/exporter/ovxlib_case/casegenerator.py", line 380, in
rknn.base.RKNNlib.app.exporter.ovxlib_case.casegenerator.CaseGenerator.generate
T   File "rknn/base/RKNNlib/app/exporter/ovxlib_case/casegenerator.py", line 352, in
rknn.base.RKNNlib.app.exporter.ovxlib_case.casegenerator.CaseGenerator._gen_special_case
T   File "rknn/base/RKNNlib/app/exporter/ovxlib_case/casegenerator.py", line 330, in
rknn.base.RKNNlib.app.exporter.ovxlib_case.casegenerator.CaseGenerator._gen_nb_file
T AttributeError: 'CaseGenerator' object has no attribute 'nbg_graph_file_path'
```

请确认：

1) 系统装有 gcc 编译工具链

2) 模型的名称只包含“字母”、“数字”、“_”，特别注意有些复制过来的模型名称会自动加上”（1）”，这时会失败。

# 2. 关于量化精度的问题

## 2.1. 量化后精度与原来模型对不上，如何调试？

- **首先确保 float 类型的精度和原始平台测试结果相近：**

(1) 使用 RKNN Toolkit 导入量化后的模型时使 rknn.build(do_quantization=False);

(2) 参考 1.1 设置 **channel_mean_value** 参数，确保其和训练模型时使用的参数相同;

(3) 务必确保测试时输入图像通道顺序为 R,G,B。（不论训练时使用的图像通道顺序如何，使用 RKNN 做测试时都按 R,G,B 输入）

(4) 在 **rknn.config** 函数里面设置 **reorder_channel** 参数，’0 1 2’代表 RGB， ’2 1 0’代表 BGR，务必和训练时候图像通道顺序一致

- **量化后的精度测试**

(1) 使用多张图进行量化，确保量化精度稳定。

在 rknn.config 中设置 batch_size 参数 (建议设置 batch_size = 200) 并且在 dataset.txt 中

给出大于 200 张图像路径用于量化。

如果显存不够，可以设置 batch_size =1, epochs=200 代替 batch_size = 200 进行量化

(2) 精度对比，尽量用较大数据集进行测试。分类网络比较 top-1,top-5 精度，检测网络比较数据集的 mAP, Recall 等。

### 2.2. 如何 dump 网络每层输出

目前 PC 模拟器可以支持 dump 出每一层网络的数据，在执行 inference 的脚本前需要设置一个环境变量，命令如下：

export NN_LAYER_DUMP=1

python xxx.py

执行完之后，会在当前目录生成每层网络的 tensor 数据文件，这样可以和别的框架的数据进行逐层比对。

注意：有些层会被合并，比如 conv+bn+scale 会合并成一个 conv，这时候就需要和原来模型的 scale 层的输出进行对比。

## 3. Caffe 模型转换常见问题

### 3.1. 转换模型时，出现“Deprecated caffe input usage”错误

该模型是旧版的 caffe 的模式，需要修改输入层成如下类似格式。

```
layer {
  name: "data"
  type: "Input"
  top: "data"
  input_param {
    shape {
      dim: 1
      dim: 3
      dim: 224
      dim: 224
    }
  }
}
```

### 3.2. 转换模型时，出现“Message type "caffe.PoolingParameter" has no field named "round_mode"”错误

Pool 层的 round_mode 字段不能识别，可以改成 ceil_model，比如原来是 round_mode: CEIL，那么可以删掉（默认 ceil_mode 为 True）或者改成 ceil_mode:True。

### 3.3. 在进行 caffe 或者其他模型转换时，出现”ValueError("'%s' is not a valid scope name" % name)”的错误

详细的错误信息类似如下：

```
T       raise ValueError("'%s' is not a valid scope name" % name)
T   ValueError: '_plus0_17' is not a valid scope name
```

对于这种情况是因为：layer name '_plusxxx' 用下划线开头不合法，要遵循 tensorflow 的命名规则：

[A-Za-z0-9.][A-Za-z0-9_.\\-/]* (for scopes at the root)

[A-Za-z0-9_.\\-/]* (for other scopes)

### 3.4. Caffe 版本的 SSD 转换失败，出现“Invalid tensor id(1), tensor(@mbox_conf_flatten_188:out0)”的错误

不支持 detectionoutput 这个 layer，可以删掉，改成在 CPU 做。

### 3.5. Caffe 版本的 SSD 模型去掉 detectionoutput 后应该有 3 个 output tensor，但 RKNN 推理时实际只返回两个 tensor

这个缺失的 tensor 是先验框，它在训练、推理阶段都一样，且对所有输入都一样，为了提高性能，RKNN-Toolkit 在模型中将相关的层优化掉了。而要得到该先验框 tensor，可以在训练阶段将先验框的 tensor 保存下，或者用 Caffe 先 inference 一次。

### 3.6. py-faster-rcnn 模型转换时出现“ValueError: Invalid tensor id(1), tensor(@rpn_bbox_pred_18:out0)”错误

与官方相比需要修改 prototxt 中的'proposal'层如下：

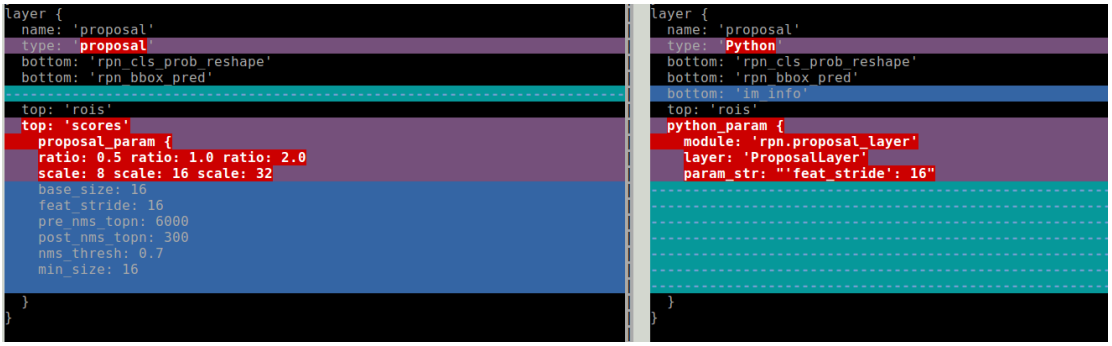

```
layer {
    name: 'proposal'
    type: 'proposal'
    bottom: 'rpn_cls_prob_reshape'
    bottom: 'rpn_bbox_pred'
    top: 'rois'
    top: 'scores'
        proposal_param {
        ratio: 0.5 ratio: 1.0 ratio: 2.0
        scale: 8 scale: 16 scale: 32
        base_size: 16
        feat_stride: 16
        pre_nms_topn: 6000
        post_nms_topn: 300
        nms_thresh: 0.7
        min_size: 16
    }
}
```

### 3.7. Caffe 模型转换时出现“E Not supported caffenet model version(v0 layer or v1 layer)”错误

详细错误如下：


主要是由于 caffe 模型的版本太旧，需要更新，更新方法如下（以 VGG16 为例）：

1) 从 https://github.com/BVLC/caffe.git 下载 Caffe 源码

2) 编译 Caffe

3) 将模型转为新的格式

./build_release/tools/**upgrade_net_proto_text** vgg16_old/vgg16.prototxt vgg16_new/vgg16.prototxt

./build_release/tools/**upgrade_net_proto_binary** vgg16_old/vgg16.caffemodel vgg16_new/vgg16.caffemodel

## 4. Tensorflow 模型转换常见问题

### 4.1. 转换 google 官方的 ssd_mobilenet_v2 模型出现“AttributeError: ‘NoneType’ object has no attribute op”错误

一个可能的原因是 input 节点没有取对，可以改成如下：

```
rknn.load_tensorflow(tf_pb='./ssd_mobilenet_v2_coco_2018_03_29/frozen_inference_graph.pb',
```

```
inputs=['FeatureExtractor/MobilenetV2/MobilenetV2/input'],
outputs=['concat', 'concat_1'],
input_size_list=[[INPUT_SIZE, INPUT_SIZE, 3]])
```

### 4.2. 转换 SSD_Resnet50_v1_FPN_640x640 模型出现“Cannot convert value dtype ([‘resource’, ‘u1’]) to a Tensorflow Dtype”错误。

需更新 RKNN Toolkit 到 0.9.8 及以后版本。

### 4.3. RKNN-Toolkit-V1.0.0 版本下，TensorFlow 模型的输出结果 shape 发生了变化？

V1.0.0 以前的版本如果模型输出的数据是按”NHWC”排列的，将转成”NCHW”。从 V1.0.0 版本开始，output 的 shape 将与原始模型保持一致，不再进行”NHWC”到”NCHW”的转换。进行后处理时请注意 channel 所在的位置。

## 5. Pytorch 模型转换常见问题

目前 RKNN Toolkit 通过 ONNX 间接支持 pytorch，因此需要将 pytorch 先转成 ONNX。如果转换过程遇到问题，请先将 RKNN Toolkit 升级到最新版本。

### 5.1. 转换时遇到类似“assert(tsr.op_type == 'Constant')”的错误

这是 pytorch 0.4.5 以后的版本引入的问题，在你的模型中，有类似“x = x.view(x.size(0), -1)”这样的语句，需要改成“x = x.view(int(x.size(0)), -1)”。

## 6. 深度神经网络模型设计建议

### 6.1. 如何设计卷积神经网络，使其能在 RKNN 上实现最佳性能

以下是我们的几点建议：

1. 卷积核设置

推荐在设计的时候尽量使用 3x3 的卷积核，这样可以实现最高的 MAC 利用率，使得 NPU 的性能最佳。

我们的 NPU 也可以支持大范围的卷积核。支持的最小内核大小为[1]，最大值为[11 * stride - 1]。同时 NPU 也支持非平方内核，不过会增加一些额外的计算开销。

2. 融合结构设计

NPU 会对卷积后面的 ReLU 和 MAX Pooling 进行融合的优化操作，能在运行中减少计算和带宽开销。所以在搭建网络时，能针对这一特性，进行设计。

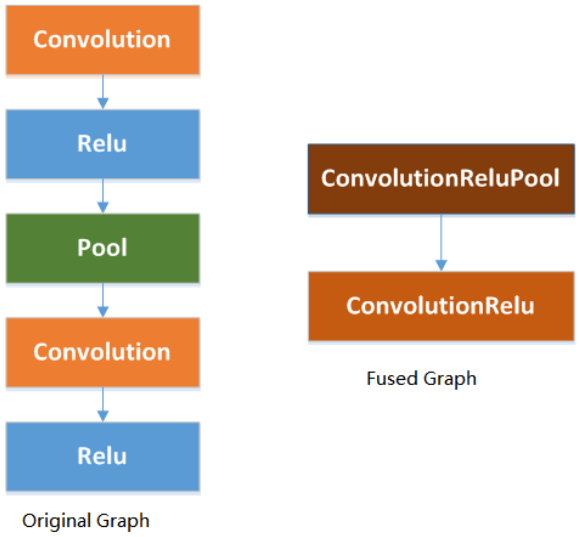


在设计网络时，卷积层后面的 ReLU 层将都会被融合。不过为了确保 MAX Pooling 层也能进行融合加速，需要尽量按照下面规则进行设计：

- pool size 必须是 2x2 或者 3x3，而步长 stride=2
- 2x2 池化的输入图片尺寸必须是偶数，而且不能有填充
- 3x3 池化的输入图片尺寸必须是非 1 的奇数，而且不能有填充
- 如果是 3x3 的池化，则水平输入大小必须小于 64（8-bit 模型）或 32（16-bit 模型）

3. 关于 2D 卷积和 Depthwise 卷积的使用

NPU 支持常规 2D 卷积和 Depthwise 卷积加速。由于 Depthiwise 卷积特定的结构，使得它对于我们量化(int8)模型不太友好，而 2D 卷积的优化效果更好。我们设计网络时建议尽量使用 2D 卷积。

如果必须使用 Depthwise 卷积，我们建议按照下面的规则进行修改，能提高量化后模型的精度:

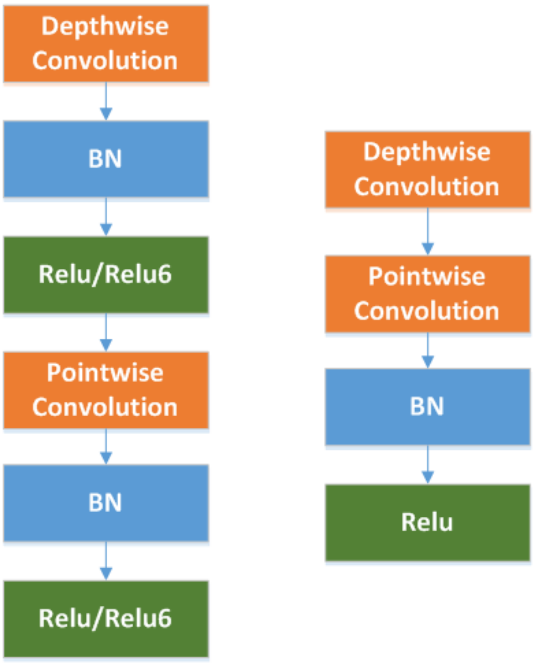


- 如果网络中的激活函数使用的是 ReLU6，建议将其都改为 ReLU。
- 在 Depthwise 卷积层的 BN 层和激活层，建议去除。
- 在训练时，针对 Depthwise 卷积层，对它的权重进行 L2 正则化。

4. 输出通道数设置

我们建议设定的卷积输出通道数是 NPU 中卷积核个数的倍数，以确保所有卷积核都被更好的利用，从而实现更高的硬件利用率。

5. 网络稀疏化

当前的神经网络存在过度参数化现象，并且在其设计时会存在很多冗余。我们的 NPU 针对稀疏矩阵，有进行跳零计算和内存提取方面的优化。所以建议在设计网络的时候，可以针对性的进行网络稀疏化设计，以利用该技术进一步提高网络性能。